

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

KHOA CÔNG NGHỆ THÔNG TIN

TRỰC QUAN HÓA DỮ LIỆU



BÁO CÁO ĐỒ ÁN CUỐI KỲ

NGƯỜI HƯỚNG DẪN:

TS. Bùi Tiến Lên

SINH VIÊN (NHÓM 2):

Nguyễn Đỗ Bảo - 23127026

Lê Nguyên Thảo - 23127118

Đinh Đại Vũ - 23127144

Vũ Hoàng Minh - 23127427

Nguyễn Thanh Owen - 23127447

Mục lục

1	Tổng Quan Về Đề Án	6
1.1	Đặt vấn đề	6
1.2	Mục tiêu và Phạm vi dự án	6
1.3	Giá trị thực tiễn	6
1.4	Nền tảng và Công cụ phát triển	7
2	Thu Thập Dữ Liệu và Tiền Xử Lý	7
2.1	Nguồn và cấu trúc dữ liệu	7
2.2	Quá trình tích hợp và làm sạch dữ liệu	7
3	Thiết Kế Dashboard và Trực Quan Hóa Dữ Liệu	8
3.1	Trang 1: Toàn cảnh kỳ thi (Overview)	8
3.1.1	Quy mô thí sinh toàn quốc qua các năm	9
3.1.2	Điểm trung bình các môn học	9
3.1.3	Phân bố quy mô thí sinh theo địa phương	10
3.1.4	Chuyển dịch cơ cấu lựa chọn khối thi	11
3.2	Trang 2: Chi tiết môn học	12
3.2.1	Phân phối điểm của từng môn học	12
3.2.2	Mức độ phân hóa và năng lực phân loại của đề thi	13
3.2.3	Xu hướng biến động phổ điểm theo thời gian	14
3.3	Trang 3: Tổ hợp xét tuyển	14
3.3.1	Phân bố tổng điểm xét tuyển theo khối thi	15
3.3.2	Mức độ cạnh tranh của nhóm thí sinh xuất sắc (Top 5%) qua các năm	15
3.3.3	Cấu trúc đóng góp của các môn thành phần trong tổ hợp	16
3.4	Trang 4: Phân tích không gian và địa lý giáo dục	17
3.4.1	Phân bố mật độ học sinh đạt điểm xuất sắc (9 - 10 điểm)	17
3.4.2	Xếp hạng mặt bằng điểm trung bình theo địa phương	18
3.4.3	Phân bố tỷ lệ học sinh khá - giỏi (≥ 8 điểm)	19
3.5	Trang 5: Phân tích tương quan và phân hóa đề thi	20
3.5.1	Mối quan hệ tương quan giữa các môn học	21
3.5.2	Đổi chuẩn chất lượng giáo dục giữa Hà Nội và TP.HCM	21
3.5.3	Đánh giá chất lượng và năng lực phân hóa của đề thi	22
4	Phân Tích Kết Quả	23
4.1	Kết quả phân tích Trang 1: Toàn cảnh kỳ thi	23
4.1.1	Sức ép quy mô gia tăng bền vững	23
4.1.2	Phân hóa mặt bằng điểm số mang tính hệ thống	23
4.1.3	Sự dịch chuyển định hướng lựa chọn khối thi	23
4.1.4	Phân bố thí sinh và các trung tâm giáo dục lớn	23
4.2	Kết quả phân tích Trang 2: Chi tiết môn học	24
4.2.1	Nhóm môn nền tảng (Toán học và Ngữ văn)	24
4.2.2	Môn Ngoại ngữ: Dấu hiệu của sự phân hóa năng lực sâu sắc	24
4.2.3	Khối Khoa học Tự nhiên (Vật lý, Hóa học, Sinh học)	24
4.2.4	Khối Khoa học Xã hội (Lịch sử, Địa lý, GDCD)	25
4.3	Kết quả phân tích Trang 3: Tổ hợp xét tuyển	25

4.3.1	Phân bố tổng điểm và hình thái cạnh tranh	25
4.3.2	Biến động mức độ cạnh tranh nhóm xuất sắc (Top 5%)	25
4.3.3	Cấu trúc đóng góp của các môn thành phần	26
4.4	Kết quả phân tích Trang 4: Không gian và địa lý giáo dục	26
4.4.1	Phân bố điểm xuất sắc (9–10 điểm)	26
4.4.2	Mặt bằng học lực chung thông qua Điểm trung bình	27
4.4.3	Chiều sâu phân hóa mũi nhọn (Tỷ lệ học sinh ≥ 8 điểm)	27
4.5	Kết quả phân tích Trang 5: Tương quan và phân hóa đề thi	27
4.5.1	Cấu trúc năng lực và tính độc lập của tổ hợp môn (Tương quan Pearson)	27
4.5.2	Đặc thù giáo dục vùng miền (Đổi chuẩn Hà Nội và TP.HCM)	28
4.5.3	Đánh giá năng lực phân hóa của cấu trúc đề thi (Phân tích Góc phần tư)	28
5	Ứng dụng Trí tuệ Nhân tạo Trong Thiết Kế và Vận Hành Hệ Thống	28
5.1	Ứng dụng AI trong quá trình thiết kế	28
5.1.1	Hệ thống AI Prompt Helper chuẩn hóa	29
5.1.2	AI hỗ trợ lựa chọn loại biểu đồ phù hợp	31
5.1.3	AI hỗ trợ thiết kế giao diện và hệ thống màu sắc	32
5.1.4	AI hỗ trợ sinh mã nguồn Streamlit và Plotly	32
5.1.5	AI hỗ trợ phân tích và diễn giải dữ liệu	33
5.1.6	AI hỗ trợ kiểm tra logic và debug	33
5.1.7	Quy trình lưu vết AI — file <code>ai-trace.md</code>	34
5.2	Tích hợp Trợ lý ảo AI phân tích dữ liệu trực tiếp (Vision-based Chatbot)	34
5.2.1	Ý tưởng thiết kế và Giá trị cốt lõi	34
5.2.2	Quy trình thu thập ngữ cảnh tự động	35
5.2.3	Luồng xử lý và trả lời truy vấn	35
6	Kết luận và hướng phát triển	36
6.1	Kết quả đạt được của đề tài	36
6.2	Hạn chế	37
6.3	Hướng phát triển tương lai	37
	References	38

Mục lục ảnh

1	Toàn cảnh kỳ thi	8
2	Quy mô thí sinh qua các năm	9
3	Điểm trung bình các môn trong năm khảo sát	10
4	Top 5 địa phương có số lượng thí sinh tham gia nhiều nhất	11
5	Cơ cấu thí sinh theo ban	12
6	Trang phân tích chi tiết điểm từng môn học	12
7	Phổ điểm chi tiết	13
8	Dải điểm phân hóa	13
9	Xu hướng biến động của phổ điểm	14
10	Trang phân tích các tổ hợp xét tuyển	15
11	Phổ điểm tổng cộng theo khối	15
12	Xu hướng biến độ của nhóm top 5% điểm cao nhất theo ban	16
13	Mức độ đóng góp của các môn thành phần trong khối bất kỳ	17
14	Trang phân tích chất lượng giáo dục theo khu vực địa lý	17
15	Mật độ thí sinh đạt điểm xuất sắc (9-10đ) ở môn bất kỳ	18
16	Xếp hạng điểm trung bình theo địa phương ở môn bất kỳ	19
17	Top 10 địa phương có tỷ lệ thí sinh đạt điểm ≥ 8 cao nhất ở môn bất kỳ	20
18	Trang phân tích đánh giá mức độ tương quan và phân hóa điểm	20
19	Ma trận tương quan giữa các môn học	21
20	Đổi chuẩn chất lượng giáo dục giữa Hà Nội và TP. HCM ở 3 môn học cốt lõi	22
21	Mức độ phân hóa của các môn	22
22	Ví dụ về sử dụng chatbot trong dashboard	36

Thông tin thành viên

STT	Họ và Tên	Mã số sinh viên	Email
1	Nguyễn Đỗ Bảo	23127026	ndbao23@clc.fitus.edu.vn
2	Lê Nguyên Thảo	23127118	lnthao23@clc.fitus.edu.vn
3	Đinh Đại Vũ	23127144	ddvu23@clc.fitus.edu.vn
4	Vũ Hoàng Minh	23127237	vhminh23@clc.fitus.edu.vn
5	Nguyễn Thanh Owen	23127451	ntowen23@clc.fitus.edu.vn

Bảng 1: Danh sách thành viên

Bảng phân công

STT	Công việc	Người thực hiện	Mã số sinh viên	Hoàn thành
1	Thu thập, làm sạch dữ liệu	Vũ Hoàng Minh	23127427	100%
2	Thiết kế khung sườn cho Dashboard	Lê Nguyên Thảo	23127118	100%
3	Thiết kế Trang 1	Lê Nguyên Thảo	23127118	100%
4	Thiết kế Trang 2	Nguyễn Đỗ Bảo	23127131	100%
5	Thiết kế Trang 3	Nguyễn Thanh Owen	23127447	100%
6	Thiết kế Trang 4	Vũ Hoàng Minh	23127427	100%
7	Thiết kế Trang 5	Đinh Đại Vũ	23127144	100%
8	Tích hợp Chatbot AI	Nguyễn Thanh Owen	23127447	100%
9	Viết báo cáo	Đinh Đại Vũ Nguyễn Đỗ Bảo	23127144 23127131	100%

Bảng 2: Bảng phân công chi tiết

1 Tổng Quan Về Đồ Án

1.1 Đặt vấn đề

Kỳ thi Trung học Phổ thông (THPT) Quốc gia là sự kiện giáo dục quan trọng bậc nhất hằng năm, tạo ra một khối lượng dữ liệu khổng lồ phản ánh toàn diện bức tranh dạy và học trên toàn quốc. Việc khai phá khối dữ liệu này không chỉ giúp cơ quan quản lý đánh giá chất lượng giáo dục mà còn hỗ trợ định hướng nghề nghiệp, xét tuyển đại học cho hàng triệu học sinh. Tuy nhiên, các báo cáo số liệu hiện nay thường mang tính chất thống kê tĩnh, rời rạc và thiếu đi một nền tảng liên kết đa chiều.

Để giải quyết bài toán đó, đồ án "**Hệ thống Phân tích và Trực quan hóa Dữ liệu Kỳ thi THPT Quốc gia Việt Nam**" được phát triển nhằm mang đến một giải pháp công nghệ toàn diện, trực quan và có tính tương tác cao.

1.2 Mục tiêu và Phạm vi dự án

Đồ án hướng tới việc xây dựng một nền tảng Dashboard phân tích dữ liệu thông minh, biến các tập dữ liệu điểm thi thô (từ năm 2020 đến năm 2024) thành những tri thức hữu ích. Hệ thống cho phép người dùng từ nhiều nhóm đối tượng khác nhau dễ dàng truy vấn, tương tác và khám phá dữ liệu thông qua giao diện Web thân thiện.

Hệ thống tập trung giải quyết 4 nhóm bài toán cốt lõi:

- **Đánh giá quy mô và xu hướng tổng thể:** Theo dõi sự biến động quy mô thí sinh dự thi và xu hướng dịch chuyển lựa chọn tổ hợp (Khoa học Tự nhiên và Khoa học Xã hội) qua các năm lịch sử.
- **Phân tích vi mô chất lượng giáo dục:** Mổ xẻ phổ điểm, đánh giá mức độ phân hóa của cấu trúc đề thi từng môn học, cũng như đo lường tính cạnh tranh của các tổ hợp xét tuyển đại học.
- **Đối chuẩn không gian địa lý:** Phân tích và trực quan hóa sự chênh lệch chất lượng giáo dục giữa 63 tỉnh/thành phố trên bản đồ toàn quốc.
- **Ứng dụng Trí tuệ Nhân tạo (AI):** Tiên phong tích hợp Trợ lý ảo AI có khả năng đọc hiểu hình ảnh biểu đồ, trực tiếp hỗ trợ người dùng giải đáp các thắc mắc về số liệu ngay trên hệ thống.

1.3 Giá trị thực tiễn

Đồ án không chỉ dừng lại ở một bài toán kỹ thuật dữ liệu mà còn mang lại những giá trị ứng dụng thực tiễn cho hệ sinh thái giáo dục:

- **Đối với Cơ quan quản lý và Nhà nghiên cứu:** Cung cấp công cụ đối chuẩn chất lượng giáo dục vùng miền; ma trận đánh giá năng lực phân hóa của đề thi giúp Ban ra đề có cơ sở điều chỉnh cho các kỳ thi tiếp theo.
- **Đối với Giáo viên và Nhà trường:** Nắm bắt sớm các xu hướng điểm số và "vùng trũng" kiến thức để kịp thời điều chỉnh phương pháp, chiến lược giảng dạy.
- **Đối với Phụ huynh và Học sinh:** Tra cứu thông tin một cách trực quan, hiểu rõ mức độ cạnh tranh của các khối ngành để đưa ra quyết định chọn trường, chọn ngành

chiến lược và an toàn.

1.4 Nền tảng và Công cụ phát triển

Để hiện thực hóa các mục tiêu phân tích thành một sản phẩm thực tế, đề tài sử dụng **Streamlit** [1] làm nền tảng cốt lõi để phát triển Hệ thống Trực quan hóa dữ liệu (Dashboard) tương tác.

Streamlit là một thư viện mã nguồn mở dựa trên ngôn ngữ Python, được thiết kế chuyên biệt cho các ứng dụng Khoa học Dữ liệu và Học máy. Việc lựa chọn công cụ này mang lại những lợi thế quan trọng cho dự án:

- **Khả năng tương tác trực quan:** Cho phép dễ dàng xây dựng các bộ lọc (chọn năm thi, chọn môn học, tỉnh thành), giúp người dùng tự do khám phá dữ liệu từ nhiều góc độ thay vì chỉ xem các báo cáo tĩnh.
- **Tích hợp liền mạch (Seamless Integration):** Streamlit tương thích hoàn hảo với các thư viện xử lý dữ liệu (Pandas), vẽ biểu đồ (Plotly) và đặc biệt là dễ dàng kết nối với các API Trí tuệ Nhân tạo để xây dựng tính năng Trợ lý ảo AI.

2 Thu Thập Dữ Liệu và Tiền Xử Lý

2.1 Nguồn và cấu trúc dữ liệu

Để phục vụ cho bài toán phân tích đa chiều và trực quan hóa bản đồ, tập dữ liệu của đề án được thu thập và tổng hợp từ 3 nguồn khác nhau:

- **Dữ liệu điểm thi lịch sử:** Bao gồm các tệp từ `thpt2020.csv` đến `thpt2024.csv`. Tập dữ liệu này được khai thác từ nền tảng chia sẻ dữ liệu Kaggle¹. Mỗi tệp chứa thông tin điểm thi của hàng triệu thí sinh trong năm tương ứng, với các trường thông tin cốt lõi là Số báo danh và điểm của 9 môn thi thành phần (Toán, Ngữ văn, Vật lý, Hóa học, Sinh học, Lịch sử, Địa lý, Giáo dục công dân, Ngoại ngữ).
- **Dữ liệu danh mục hành chính:** Tệp `mavung.csv` được tự tổng hợp và xây dựng. Tệp này đóng vai trò như một bảng tham chiếu, chứa danh sách mã vùng tương ứng với tên gọi của 63 tỉnh và thành phố trên cả nước.
- **Dữ liệu không gian địa lý:** Tệp `vn_geo.json` chứa tọa độ ranh giới hành chính của các tỉnh và thành phố tại Việt Nam (bao gồm cả quần đảo Hoàng Sa và Trường Sa). Dữ liệu này được thu thập từ nền tảng cung cấp bản đồ số SimpleMaps². Đây là dữ liệu cần có để hệ thống có thể vẽ được biểu đồ phân bố theo vùng miền.

2.2 Quá trình tích hợp và làm sạch dữ liệu

Do dữ liệu được tổng hợp từ nhiều nguồn khác nhau, các thao tác tiền xử lý cụ thể đã được tiến hành như sau nhằm đảm bảo tính đồng bộ và toàn vẹn của dữ liệu:

- **Đồng bộ và nối dữ liệu điểm thi:** Đối với các tệp dữ liệu lịch sử từ `thpt2020.csv` đến `thpt2024.csv`, các cột dữ liệu (như tên môn học, số báo danh) được đổi tên về

¹Nguồn tập dữ liệu điểm thi: <https://www.kaggle.com/datasets/harrythai/d-liu-im-thi-thpt-q-uc-gia-2020-2024>

²Nguồn dữ liệu tọa độ bản đồ: <https://simplemaps.com/gis/country/vn>

cùng một định dạng chuẩn chung. Sau khi thống nhất tên cột, tất cả các tệp này được nối lại thành một tập dữ liệu tổng. Tiếp theo, quá trình rà soát được thực hiện nhằm xóa bỏ hoàn toàn các dòng dữ liệu bị rỗng (những dòng mà toàn bộ các cột đều không có giá trị) để đảm bảo bộ dữ liệu hoàn toàn sạch trước khi đưa vào phân tích.


- **Tích hợp danh mục địa phương:** Tệp `mavung.csv` được sử dụng làm bảng dữ liệu gốc. Để xác định địa phương của từng thí sinh, 2 ký tự đầu tiên của cột Số báo danh được trích xuất để làm mã vùng. Sau đó, thao tác dò tìm và ghép bảng được thực hiện dựa trên mã vùng này với tệp `mavung.csv` để lấy ra tên tỉnh hoặc thành phố tương ứng.
- **Đồng bộ hóa dữ liệu bản đồ:** Dữ liệu tọa độ gốc trong tệp `vn_geo.json` có tên một số địa phương chưa khớp với bảng mã vùng (ví dụ: khác biệt về cách viết tắt hay dấu câu). Để khắc phục, tệp bản đồ này được can thiệp trực tiếp để sửa lại tên các tỉnh bên trong sao cho trùng khớp hoàn toàn với tên gọi trong bảng `mavung.csv`. Thao tác này là yêu cầu bắt buộc để biểu đồ trên hệ thống có thể nhận diện và tô màu chính xác cho toàn bộ 63 tỉnh và thành phố.

3 Thiết Kế Dashboard và Trực Quan Hóa Dữ Liệu

Hệ thống phân tích được thiết kế dưới dạng Dashboard tương tác, chia thành 5 phân hệ (Tab) chính. Mỗi phân hệ tập trung giải quyết một khía cạnh nghiệp vụ cụ thể của kỳ thi. Dưới đây là chi tiết thiết kế và luồng phân tích (Analytical Flow) được áp dụng cho hệ thống.

3.1 Trang 1: Toàn cảnh kỳ thi (Overview)

Phân hệ này đóng vai trò là lớp tổng quan, cung cấp bức tranh vĩ mô về quy mô kỳ thi, chất lượng điểm số cơ bản và sự phân luồng khối thi trước khi đi sâu vào các phân tích chi tiết.



Hình 1: Toàn cảnh kỳ thi

3.1.1 Quy mô thí sinh toàn quốc qua các năm

- **Dữ liệu (What):** Trục X biểu diễn Năm thi (Biến thời gian), Trục Y biểu diễn Tổng số lượng thí sinh dự thi (Biến định lượng).
- **Mục tiêu phân tích (Why):** Tổng hợp tổng khối lượng thí sinh và nhận diện xu hướng biến động (mở rộng hay thu hẹp) quy mô của hệ thống giáo dục qua các năm.
- **Phương pháp trực quan hóa (How):** Biểu đồ miền (Area Chart) được ứng dụng. Diện tích vùng màu dưới đường xu hướng giúp trực quan hóa sức ép quy mô tích lũy theo thời gian một cách rõ ràng hơn so với biểu đồ đường (Line Chart) truyền thống.



Hình 2: Quy mô thí sinh qua các năm

3.1.2 Điểm trung bình các môn học


- **Dữ liệu (What):** Trục Y là Tên 9 môn thi THPT Quốc gia (Biến phân loại), Trục X là Điểm trung bình của từng môn (Biến định lượng).
- **Mục tiêu phân tích (Why):** Xếp hạng hiệu suất học tập và đối chuẩn mức độ khó/dễ cơ bản giữa các môn học trong cùng một năm thi.
- **Phương pháp trực quan hóa (How):** Biểu đồ cột ngang (Horizontal Bar Chart) được lựa chọn. Cách hiển thị này giúp các nhãn văn bản có độ dài lớn (như Ngoại ngữ, Giáo dục Công dân) được hiển thị trọn vẹn. Các cột được sắp xếp theo giá trị tăng dần giúp nhanh chóng xác định cực trị (môn có điểm cao nhất và thấp nhất).



Hình 3: Điểm trung bình các môn trong năm khảo sát

3.1.3 Phân bố quy mô thí sinh theo địa phương

- **Dữ liệu (What):** Trục Y là Tên Tỉnh/Thành phố, Trục X là Số lượng thí sinh dự thi.
- **Mục tiêu phân tích (Why):** Xác định cực trị bằng cách lọc ra Top 5 địa phương có lượng thí sinh tham gia đông đảo nhất, từ đó đánh giá mức độ tập trung áp lực giáo dục theo các vùng trọng điểm.
- **Phương pháp trực quan hóa (How):** Biểu đồ cột ngang (Horizontal Bar Chart) giới hạn Top 5 được sử dụng thay vì hiển thị toàn bộ 63 tỉnh/thành, nhằm tránh hiện tượng quá tải thông tin (Information Overload) và hướng sự tập trung vào các "điểm nóng" giáo dục.




Hình 4: Top 5 địa phương có số lượng thí sinh tham gia nhiều nhất

3.1.4 Chuyển dịch cơ cấu lựa chọn khối thi

Để theo dõi sự phân luồng định hướng nghề nghiệp (chọn Khoa học Tự nhiên hay Khoa học Xã hội), một thiết kế trực quan kép (Dual-chart design) đã được triển khai:


- **Dữ liệu (What):** Biến phân loại (Tổ hợp khối thi: KHTN, KHXH, Không đầy đủ), Biến định lượng (Tỷ lệ phần trăm thí sinh) và Biến thời gian (Năm thi).
- **Mục tiêu phân tích (Why):** Đánh giá cơ cấu tỷ trọng phân bổ khối thi trong một năm cụ thể (tính thời điểm) và theo dõi xu hướng dịch chuyển định hướng nghề nghiệp của học sinh qua nhiều năm liên tiếp (tính xu hướng).
- **Phương pháp trực quan hóa (How):** Kết hợp hai biểu đồ đặt cạnh nhau nhằm hỗ trợ và khắc phục nhược điểm của từng loại:
 - *Biểu đồ vành khuyên (Donut Chart):* Thể hiện cơ cấu tỷ trọng phần trăm tĩnh của các khối thi trong năm học được chọn.
 - *Biểu đồ cột chồng 100% (100% Stacked Bar Chart):* Khắc phục điểm yếu thiếu chiều thời gian của Donut Chart bằng cách dàn trải tỷ trọng qua các năm lịch sử, giúp trực quan hóa rõ ràng luồng chuyển dịch phần trăm.



Hình 5: Cơ cấu thí sinh theo ban

3.2 Trang 2: Chi tiết môn học

Phân hệ này tập trung phân tích vi mô vào từng môn học riêng biệt, nhằm đánh giá chất lượng đề thi, mức độ phân hóa năng lực thí sinh và theo dõi sự biến động của phổ điểm qua các năm.




Hình 6: Trang phân tích chi tiết điểm từng môn học

3.2.1 Phân phối điểm của từng môn học

- **Dữ liệu (What):** Toàn bộ dải điểm của một môn học trong một năm cụ thể (từ 0 đến 10) và biến định lượng là tần suất (số lượng thí sinh) đạt được tại từng mức điểm.
- **Mục tiêu phân tích (Why):** Đánh giá xu hướng tập trung của điểm số nhằm xác định mức điểm phổ biến nhất, từ đó đưa ra nhận định tổng quan về độ khó của đề thi (thiên về dễ, trung bình hay khó). Đồng thời, giúp nhận diện các hiện tượng bất thường như "dồn cụm điểm" tại một ngưỡng nhất định.


- **Phương pháp trực quan hóa (How):** Biểu đồ phân phối tần suất (Histogram) được sử dụng để trực quan hóa hình dáng của phổ điểm, cung cấp góc nhìn rõ nét về cách điểm số phân bố trên toàn tập thí sinh.



Hình 7: Phổ điểm chi tiết

3.2.2 Mức độ phân hóa và năng lực phân loại của đề thi


- **Dữ liệu (What):** Các tham số thống kê mô tả của toàn bộ điểm số trong một môn, bao gồm mức điểm trung tâm, độ phân tán (hộp) và các giá trị ngoại lệ (outliers).
- **Mục tiêu phân tích (Why):** Đo lường độ "dàn trải" của điểm số nhằm đánh giá khả năng phân loại học sinh (giỏi, khá, trung bình, yếu) của cấu trúc đề. Nhận diện rõ các môn học có tính "gom cụm" (ít phân hóa) hoặc "trải rộng" (phân hóa mạnh).
- **Phương pháp trực quan hóa (How):** Biểu đồ hộp (Boxplot) được áp dụng. Công cụ này thể hiện cực kỳ hiệu quả trung vị, các khoảng tứ phân vị và bóc tách các điểm số ngoại lệ mà biểu đồ Histogram có thể bỏ sót.



Hình 8: Dải điểm phân hóa

3.2.3 Xu hướng biến động phổ điểm theo thời gian

- **Dữ liệu (What):** Chuỗi phân phối điểm của cùng một môn học được đặt trên trục thời gian trải dài qua nhiều năm liên tiếp.
- **Mục tiêu phân tích (Why):** So sánh tính ổn định về độ khó của đề thi qua các năm. Theo dõi hướng dịch chuyển của đỉnh phổ điểm (lên cao hoặc xuống thấp) để xác định những năm có kết quả thi cao hoặc thấp bất thường so với mặt bằng chung lịch sử.
- **Phương pháp trực quan hóa (How):** Biểu đồ đường đa tuyến (Multi-year Line Chart) được sử dụng. Việc xếp chồng các đường phổ điểm của nhiều năm trên cùng một hệ trục tọa độ cho phép đối sánh trực tiếp hình dáng và sự dịch chuyển của chúng một cách trực quan nhất.



Hình 9: Xu hướng biến động của phổ điểm

3.3 Trang 3: Tổ hợp xét tuyển


Phân hệ này cung cấp góc nhìn toàn diện về cấu trúc điểm xét tuyển Đại học và mức độ cạnh tranh giữa các tổ hợp truyền thống (như A00, A01, B00, C00, D01,...). Các phân tích tại đây hỗ trợ học sinh và các nhà quản lý giáo dục đưa ra quyết định dựa trên dữ liệu thực chứng (data-driven) thay vì cảm tính.



Hình 10: Trang phân tích các tổ hợp xét tuyển

3.3.1 Phân bố tổng điểm xét tuyển theo khối thi

- **Dữ liệu (What):** Tổng điểm 3 môn cấu thành nên tổ hợp xét tuyển của những thí sinh đã hoàn thành đầy đủ bài thi, được phân tách chi tiết theo từng năm.
- **Mục tiêu phân tích (Why):** Đánh giá mức độ phân bố năng lực của thí sinh trên toàn hệ thống và đối chuẩn độ khó tương đối giữa các khối. Qua đó, nhận diện được mức độ cạnh tranh chung và cung cấp cơ sở để thí sinh đánh giá "độ an toàn" khi đăng ký nguyện vọng.
- **Phương pháp trực quan hóa (How):** Biểu đồ phân phối tần suất (Histogram) được sử dụng để trực quan hóa phổ điểm tổng, cho phép quan sát rõ ràng vùng điểm tập trung đông thí sinh nhất của từng khối thi.




Hình 11: Phổ điểm tổng cộng theo khối

3.3.2 Mức độ cạnh tranh của nhóm thí sinh xuất sắc (Top 5%) qua các năm

- **Dữ liệu (What):** Chuỗi dữ liệu về ngưỡng tổng điểm đại diện cho nhóm 5% thí sinh có thành tích cao nhất (Bách phân vị thứ 95 - Percentile 95) của từng khối thi trong nhiều năm liên tiếp.


- **Mục tiêu phân tích (Why):** Theo dõi xu hướng biến động về mức độ "khó đạt điểm cao" qua các năm. Phân tích này giúp phát hiện xu hướng lạm phát điểm số hoặc sự sụt giảm chất lượng đầu vào, từ đó hỗ trợ các trường Đại học có cơ sở điều chỉnh chiến lược tuyển sinh và điểm chuẩn.
- **Phương pháp trực quan hóa (How):** Biểu đồ đường (Line Chart) theo trục thời gian được triển khai để trực quan hóa quỹ đạo biến động của ngưỡng điểm xuất sắc, giúp dễ dàng so sánh chéo mức độ cạnh tranh giữa các khối trong cùng một ban (KHTN hoặc KHXH).



Hình 12: Xu hướng biến độ của nhóm top 5% điểm cao nhất theo ban

3.3.3 Cấu trúc đóng góp của các môn thành phần trong tổ hợp


- **Dữ liệu (What):** Điểm trung bình của từng bài thi thành phần (ví dụ: Toán, Vật lý, Hóa học đối với khối A00), được trích xuất và tính toán riêng cho nhóm thí sinh đạt Top 5% tổng điểm cao nhất khối.
- **Mục tiêu phân tích (Why):** Phân tích "hồ sơ điểm số" của nhóm thí sinh xuất sắc nhằm xác định môn học nào đóng vai trò chủ đạo (kéo điểm) hoặc môn nào có nguy cơ trở thành điểm yếu (rào cản). Kết quả này đóng vai trò then chốt trong việc định hướng chiến lược ôn tập trọng tâm cho học sinh.
- **Phương pháp trực quan hóa (How):** Biểu đồ mạng nhện (Radar Chart) được ứng dụng. Thiết kế đa trục của biểu đồ này đặc biệt phù hợp để biểu diễn đồng thời và so sánh sự cân bằng về mức độ đóng góp của 3 môn học trong cùng một không gian hình học.



Hình 13: Mức độ đóng góp của các môn thành phần trong khối bất kỳ

3.4 Trang 4: Phân tích không gian và địa lý giáo dục

Phân hệ này cung cấp góc nhìn không gian (Spatial Analysis) đối với dữ liệu điểm thi THPT Quốc gia, giúp nhận diện sự phân hóa chất lượng giáo dục theo vùng miền. Bằng cách kết hợp đa chiều các chỉ số (số lượng tuyệt đối, điểm trung bình và tỷ lệ tương đối), phân hệ hỗ trợ đánh giá toàn diện năng lực học tập và sự chênh lệch giáo dục giữa 63 tỉnh/thành phố trên cả nước.




Hình 14: Trang phân tích chất lượng giáo dục theo khu vực địa lý

3.4.1 Phân bố mật độ học sinh đạt điểm xuất sắc (9 - 10 điểm)

- Dữ liệu (What):** Dữ liệu không gian (tọa độ ranh giới 63 tỉnh/thành) kết hợp với tập giá trị điểm xuất sắc (từ 9 đến 10 điểm) của toàn bộ thí sinh được phân cụm theo từng địa phương.


- **Mục tiêu phân tích (Why):** Đánh giá mức độ phân bố đồng đều của nhóm học sinh xuất sắc trên toàn quốc; từ đó phát hiện các "điểm nóng" (hotspots) về thành tích học tập và đối chuẩn sự chênh lệch chất lượng giáo dục giữa các vùng miền.
- **Phương pháp trực quan hóa (How):** Bản đồ nhiệt không gian (Choropleth Map) được triển khai. Thang độ màu (Color gradient) được sử dụng để mã hóa mật độ số lượng học sinh đạt điểm 9-10, kết hợp cùng tính năng tương tác (Hover) để hiển thị chi tiết thông tin khi người dùng di chuột qua từng ranh giới hành chính.



Hình 15: Mật độ thí sinh đạt điểm xuất sắc (9-10đ) ở môn bất kỳ

3.4.2 Xếp hạng mật bằng điểm trung bình theo địa phương


- **Dữ liệu (What):** Giá trị điểm trung bình cộng của từng môn học, được tổng hợp và phân nhóm theo từng đơn vị hành chính cấp tỉnh.
- **Mục tiêu phân tích (Why):** Đo lường mật bằng học lực tổng thể của khu vực thay vì chỉ tập trung vào cực trị xuất sắc. Kết quả phân tích giúp đối chuẩn chất lượng giáo dục diện rộng giữa các tỉnh/thành, qua đó tìm ra những địa phương duy trì được thành tích học tập cao và ổn định.
- **Phương pháp trực quan hóa (How):** Biểu đồ cột ngang (Horizontal Bar Chart) được áp dụng để trích xuất và xếp hạng Top 10 địa phương có điểm trung bình cao nhất, giúp tối ưu hóa không gian hiển thị và định hướng sự chú ý của người xem vào nhóm dẫn đầu.



Hình 16: Xếp hạng điểm trung bình theo địa phương ở môn bất kỳ

3.4.3 Phân bố tỷ lệ học sinh khá - giỏi (≥ 8 điểm)


- **Dữ liệu (What):** Tỷ lệ phần trăm được chuẩn hóa từ phép chia giữa số lượng thí sinh đạt từ 8 điểm trở lên và tổng số thí sinh dự thi tại cùng một địa phương.
- **Mục tiêu phân tích (Why):** Khắc phục điểm yếu mất cân bằng quy mô dân số (các tỉnh thành đông dân thường áp đảo về số lượng tuyệt đối). Việc đo lường bằng tỷ lệ phần trăm giúp đưa các tỉnh về cùng một hệ quy chiếu công bằng, qua đó phản ánh chính xác chiều sâu chất lượng giáo dục và nhận diện những địa phương thực sự có tỷ lệ học sinh khá - giỏi nổi bật.
- **Phương pháp trực quan hóa (How):** Biểu đồ cột ngang (Horizontal Bar Chart) tiếp tục được sử dụng để trực quan hóa Top 10 địa phương dẫn đầu về tỷ lệ phần trăm học sinh khá - giỏi, tạo tính nhất quán trong thiết kế giao diện theo biểu đồ chuẩn.



Hình 17: Top 10 địa phương có tỷ lệ thí sinh đạt điểm ≥ 8 cao nhất ở môn bất kỳ

3.5 Trang 5: Phân tích tương quan và phân hóa đề thi


Phân hệ cuối cùng này cung cấp góc nhìn chuyên sâu về mặt thống kê và cấu trúc dữ liệu giáo dục. Các phân tích tại đây tập trung giải quyết ba bài toán cốt lõi: đo lường mối quan hệ tương quan giữa các môn học, đối chuẩn chất lượng giáo dục giữa các trung tâm đô thị lớn, và đánh giá năng lực phân hóa của cấu trúc đề thi.



Hình 18: Trang phân tích đánh giá mức độ tương quan và phân hóa điểm

3.5.1 Môi quan hệ tương quan giữa các môn học

- **Dữ liệu (What):** Tập dữ liệu chứa điểm số của toàn bộ thí sinh ở 9 môn thi thành phần, được thu thập và phân tách chi tiết theo từng năm khảo sát.
- **Mục tiêu phân tích (Why):** Đo lường mức độ liên hệ toán học giữa các môn học nhằm phát hiện các nhóm kỹ năng có xu hướng "đồng biến" (ví dụ: thí sinh đạt điểm cao môn Toán thường có xu hướng điểm cao môn Vật lý). Kết quả này giúp phác họa cấu trúc năng lực học tập theo khối tự nhiên - xã hội và hỗ trợ định hướng chiến lược học tập liên môn hiệu quả.
- **Phương pháp trực quan hóa (How):** Biểu đồ ma trận tương quan (Correlation Heatmap) dựa trên hệ số Pearson được ứng dụng. Thang màu nhiệt (Color gradient) giúp biểu diễn trực quan cường độ và chiều hướng tương quan (từ âm sang dương) giữa tất cả các cặp môn học trong cùng một không gian ma trận.



Hình 19: Ma trận tương quan giữa các môn học

3.5.2 Đối chuẩn chất lượng giáo dục giữa Hà Nội và TP.HCM

- **Dữ liệu (What):** Điểm trung bình của ba môn học công cụ cốt lõi (Toán, Ngữ Văn, Ngoại ngữ), được lọc và tổng hợp riêng cho tập thí sinh thuộc hai thành phố lớn nhất cả nước là Hà Nội và TP. Hồ Chí Minh.
- **Mục tiêu phân tích (Why):** Thực hiện so sánh đối đầu (Head-to-head comparison) để đánh giá năng lực học tập và quan sát mức độ cạnh tranh giáo dục giữa hai vùng đô thị trọng điểm. Phân tích này giúp xác định rõ môn học lợi thế của từng địa phương và mức độ chênh lệch năng lực thực tế.
- **Phương pháp trực quan hóa (How):** Biểu đồ quả tạ (Dumbbell Chart) được triển khai. Thiết kế này đặc biệt tối ưu cho việc so sánh cặp giá trị: mỗi môn học được biểu diễn bằng hai điểm cực (đại diện cho hai thành phố), và chiều dài của đoạn thẳng nối giữa hai điểm phản ánh trực tiếp khoảng cách chênh lệch về điểm trung bình.



Hình 20: Đối chuẩn chất lượng giáo dục giữa Hà Nội và TP. HCM ở 3 môn học cốt lõi

3.5.3 Đánh giá chất lượng và năng lực phân hóa của đề thi

- **Dữ liệu (What):** Ba tham số thống kê vĩ mô được trích xuất cho từng môn học: Điểm trung bình, Độ lệch chuẩn (Standard Deviation) và Tổng số lượng thí sinh dự thi.
- **Mục tiêu phân tích (Why):** Khảo sát toàn diện chất lượng đề thi dựa trên hai tiêu chí thống kê cơ bản: Độ khó (thông qua điểm trung bình) và Khả năng phân loại (thông qua độ lệch chuẩn). Phân tích này cung cấp cơ sở khoa học để xác định đề thi của môn nào đang gặp tình trạng lạm phát điểm, môn nào quá khó nhưng kém phân hóa, từ đó hỗ trợ Ban ra đề có góc nhìn thực chứng để cải thiện cấu trúc đề.
- **Phương pháp trực quan hóa (How):** Biểu đồ phân góc phần tư (Quadrant Chart) kết hợp biểu đồ bong bóng (Bubble Chart) được thiết lập. Hệ trục tọa độ giao cắt giữa Điểm trung bình (Trục X) và Độ lệch chuẩn (Trục Y) chia không gian thành 4 vùng phân tích chiến lược: Dễ & phân hóa tốt, Khó & phân hóa tốt, Dễ & kém phân hóa, Khó & kém phân hóa. Đồng thời, độ lớn của bong bóng (Bubble size) được sử dụng để mã hóa quy mô số lượng thí sinh.



Hình 21: Mức độ phân hóa của các môn

4 Phân Tích Kết Quả

4.1 Kết quả phân tích Trang 1: Toàn cảnh kỳ thi

4.1.1 Sức ép quy mô gia tăng bền vững

- **Quan sát:** Quy mô thí sinh dự thi có sự tăng trưởng ổn định qua từng năm, từ 870.486 thí sinh (năm 2020) lên 1.061.604 thí sinh (năm 2024), tương đương mức tăng xấp xỉ 22% sau 5 năm.
- **Nhận định:** Sự mở rộng quy mô một cách đồng đều và không bị gián đoạn (ngay cả trong những năm đại dịch) là một tín hiệu tích cực, minh chứng cho mức độ phổ cập giáo dục bậc trung học ngày càng được nâng cao trên toàn quốc.
- **Ý nghĩa thực tiễn:** Sự phình to liên tục của nguồn tuyển gây áp lực trực tiếp lên hệ thống xét tuyển Đại học, đòi hỏi các cơ sở đào tạo phải linh hoạt điều chỉnh ngưỡng đảm bảo chất lượng đầu vào để tránh tình trạng quá tải.

4.1.2 Phân hóa mặt bằng điểm số mang tính hệ thống

- **Quan sát:** Dù mặt bằng điểm chung có biến động qua từng năm, môn Giáo dục Công dân (GD CD) và Ngoại ngữ luôn cố định ở hai thái cực cao nhất và thấp nhất. Đặc biệt, khoảng cách điểm trung bình giữa hai môn này luôn duy trì ở mức rất rộng, dao động từ 2 đến 4 điểm xuyên suốt giai đoạn 2020–2024.
- **Nhận định:** Sự chênh lệch cực đoan này bộc lộ những vấn đề mang tính hệ thống. Việc GD CD luôn chạm đỉnh phản ánh tình trạng lạm phát điểm kéo dài, khiến môn học này gần như mất khả năng phân loại thí sinh xuất sắc. Ở chiều ngược lại, Ngoại ngữ luôn chạm đáy khẳng định đây vẫn là "vùng trũng" học lực cấp quốc gia, chưa có dấu hiệu cải thiện đột phá.

4.1.3 Sự dịch chuyển định hướng lựa chọn khối thi

- **Quan sát:** Tổ hợp Khoa học Xã hội (KHXH) giữ vững vị thế độc tôn với tỷ lệ lựa chọn duy trì ổn định quanh mức 55% qua các năm. Đáng chú ý, tỷ lệ thí sinh "Thi không đầy đủ tổ hợp" có xu hướng tăng đều đặn từ 11,7% (2020) lên 13,1% (2024).
- **Nhận định:** Sự gia tăng của nhóm thi không đầy đủ tổ hợp cho thấy học sinh đang chủ động thay đổi hành vi, chuyển dịch chiến lược sang các phương thức xét tuyển đại học thay thế (như xét học bạ, thi đánh giá năng lực) thay vì phụ thuộc hoàn toàn vào tổ hợp 3 môn truyền thống.

4.1.4 Phân bố thí sinh và các trung tâm giáo dục lớn

- **Quan sát:** Hà Nội và TP. Hồ Chí Minh tiếp tục là hai trung tâm tập trung thí sinh lớn nhất cả nước, chiếm quy mô áp đảo (gấp khoảng 3 lần so với địa phương xếp thứ 3 là Hải Phòng). Các tỉnh như Thanh Hóa và Nghệ An liên tục lọt vào Top 5 địa phương có lượng thí sinh đông nhất.
- **Nhận định:** Sự tập trung tại hai đô thị đặc biệt phản ánh rõ đặc điểm phân bố dân cư và mạng lưới giáo dục. Riêng sự góp mặt của các tỉnh miền Trung (Thanh Hóa,

Nghệ An) chủ yếu xuất phát từ lợi thế quy mô dân số đông tự nhiên của vùng, tạo ra một nguồn thí sinh khổng lồ hàng năm.

4.2 Kết quả phân tích Trang 2: Chi tiết môn học

4.2.1 Nhóm môn nền tảng (Toán học và Ngữ văn)

- **Môn Toán (Tính chuẩn hóa cao):** Phổ điểm môn Toán duy trì hình dáng phân phối tiệm cận chuẩn (Normal distribution), hơi lệch trái với đỉnh (Mode) cực kỳ ổn định trong vùng 7,5 – 8,0 qua cả 5 năm. Đường cong mượt mà và không có biến động lớn cho thấy cấu trúc đề thi Toán được xây dựng rất chuẩn mực, duy trì tốt vai trò thước đo ổn định.
- **Môn Ngữ văn (Đặc trưng chấm tự luận và sai số kỹ thuật):** Phổ điểm ghi nhận hiện tượng "răng cưa" (Spiky effect) dày đặc với các đỉnh nhọn liên tiếp. Hiện tượng này được giải thích bởi hai yếu tố:
 - *Cơ chế chấm thi:* Điểm số là trung bình cộng của hai vòng chấm độc lập và được làm tròn đến hai chữ số thập phân (ví dụ: 7,625 → 7,63). Việc này tạo ra các mức điểm lẻ có mật độ thí sinh thấp, xen kẽ giữa các mức điểm phổ biến.
 - *Tâm lý hội tụ:* Dữ liệu hội tụ mạnh tại các nấc điểm 0,25 theo barem chấm thi chuẩn, tạo thành các đỉnh nhọn áp đảo so với các điểm số trung gian.

Nhìn chung, phổ điểm có xu hướng lệch trái nhẹ, tập trung chủ yếu trong khoảng 6,5 – 7,5 điểm, phản ánh sự phân hóa đặc trưng của môn tự luận.

4.2.2 Môn Ngoại ngữ: Dấu hiệu của sự phân hóa năng lực sâu sắc

- **Quan sát hình dáng:** Biểu đồ Ngoại ngữ có hình dáng đặc thù nhất toàn hệ thống với độ phân tán rất rộng. Đỉnh phổ điểm thường nằm ở mức dưới trung bình (4,0 – 5,0). Đặc biệt, vào năm 2021, phổ điểm xuất hiện hiện tượng "hai đỉnh" (Bimodal distribution) hình yên ngựa cực kỳ rõ rệt.
- **Nhận định:** Hình dáng phổ điểm này phản ánh sự đứt gãy trong năng lực ngoại ngữ của học sinh cả nước. Nó chia thí sinh thành hai nhóm tách biệt: một nhóm có điểm số thấp (do thiếu điều kiện tiếp cận) và một nhóm có điểm số rất cao (thường ở các đô thị lớn). Sự bất bình đẳng này là rào cản lớn nhất của hệ thống giáo dục ngoại ngữ hiện tại.

4.2.3 Khối Khoa học Tự nhiên (Vật lý, Hóa học, Sinh học)

- **Vật lý và Hóa học:** Cả hai môn đều có phổ điểm hình dáng tháp chuông cân đối, đỉnh hội tụ ở mức khá giỏi (7,5 – 8,0) và có sự đồng nhất cao qua các năm. Điều này cho thấy đây là hai môn học có tính phân loại thí sinh xét tuyển Đại học tốt nhất.
- **Sinh học:** Trái ngược với Lý và Hóa, Sinh học là môn "kén" thí sinh hơn. Đỉnh phổ điểm dao động ở mức thấp (5,0 – 6,5) và có sự trôi sụt không ổn định qua các năm. Đề thi Sinh học thường được đánh giá là dài và nặng về lý thuyết phân tích, tạo ra phổ điểm phân bố thấp hơn hẳn so với mặt bằng chung khối KHTN.

4.2.4 Khối Khoa học Xã hội (Lịch sử, Địa lý, GDCD)

- **Môn Lịch sử (Sự dịch chuyển tịnh tiến):** Phổ điểm Lịch sử ghi nhận sự thay đổi ngoạn mục nhất. Trong giai đoạn 2020–2021, đỉnh phổ điểm nằm ở mức cực kỳ thấp (4,0 – 4,5). Tuy nhiên, từ năm 2022 đến 2024, toàn bộ hình chuông đã dịch chuyển mạnh mẽ sang phải (đạt đỉnh ở 6,5 – 7,0). Sự "lột xác" này là minh chứng cho tác động của việc đổi mới phương pháp giảng dạy và giảm nhẹ mức độ đánh đố trong đề thi.
- **Môn Địa lý:** Hình dáng phổ điểm duy trì sự cân bằng, ổn định với đỉnh dồn về mức 7,0 – 7,5.
- **Môn GDCD (Sự lệch trái cực đoan):** Biểu đồ GDCD có đặc trưng lệch trái hoàn toàn (Extreme left-skewed), đuôi đồ thị dốc ngược lên với đỉnh hội tụ tại mức 8,5 – 9,0. Tỷ lệ điểm 10 dày đặc cho thấy hiện tượng lạm phát điểm, biến GDCD thuần túy trở thành môn "gánh điểm" xét tốt nghiệp và mất đi chức năng sàng lọc thí sinh xuất sắc.

4.3 Kết quả phân tích Trang 3: Tổ hợp xét tuyển

Phân hệ này bóc tách cấu trúc điểm xét tuyển và mức độ cạnh tranh giữa các tổ hợp. Dữ liệu bộc lộ sự phân cực rất rõ rệt về hành vi cạnh tranh ở nhóm xuất sắc giữa hai ban Khoa học Tự nhiên (KHTN) và Khoa học Xã hội (KHXH).

4.3.1 Phân bố tổng điểm và hình thái cạnh tranh

- **Ban Khoa học Tự nhiên (KHTN):**
 - **Quan sát:** Phổ điểm có đuôi phải dốc gắt (steep right tail), số lượng thí sinh giảm mạnh ở các mức điểm tuyệt đối.
 - **Ý nghĩa thực tiễn:** Cấu trúc đề phân hóa rất tốt. Sự cạnh tranh vô cùng khắt khe, ranh giới trúng tuyển phụ thuộc hoàn toàn vào năng lực giải quyết các câu hỏi vận dụng cao.
- **Ban Khoa học Xã hội (KHXH):**
 - **Quan sát:** Phổ điểm có đuôi phải thoải và "dày" hơn (fat right tail) tại vùng điểm cao (26–28 điểm).
 - **Ý nghĩa thực tiễn:** Phản ánh tình trạng lạm phát điểm cục bộ. Cạnh tranh ở khối này không nằm ở việc giải câu hỏi khó, mà biến thành bài toán tối thiểu hóa sai sót do mật độ thí sinh dồn ứ quá đông.

4.3.2 Biến động mức độ cạnh tranh nhóm xuất sắc (Top 5%)

- **Ban KHTN:**
 - **Quan sát:** Ngưỡng Top 5% khối A00, A01 cao và đi ngang qua các năm. Các khối chứa Sinh học (A02, B00) luôn có ngưỡng điểm thấp hơn hẳn.

- **Ý nghĩa thực tiễn:** Mức độ cạnh tranh cực kỳ ổn định. Môn Sinh học đóng vai trò như một màng lọc khắt khe, kéo tổng điểm xuống nhưng quyết định lợi thế trúng tuyển nhóm ngành Y - Dược.

- **Ban KHXH:**

- **Quan sát:** Ngưỡng Top 5% tăng liên tục và biến động mạnh. Các khối chứa Giáo dục công dân (GD CD) như C19, C20 luôn dẫn đầu.
- **Ý nghĩa thực tiễn:** Khối KHXH nhạy cảm với cấu trúc đề. Tổ hợp có GD CD mang lại ưu thế điểm số tuyệt đối, giúp thí sinh dễ dàng đạt ngưỡng an toàn cao hơn các khối truyền thống.

4.3.3 Cấu trúc đóng góp của các môn thành phần

- **Ban KHTN:**

- **Khối A00:** Điểm Toán có xu hướng giảm tỷ trọng từ 2023–2024, nhường không gian bứt phá cho Vật lý và Hóa học.
- **Khối A01:** Ngoại ngữ thiết lập vị thế chủ đạo, luôn đạt mức điểm cao nhất trong nhóm Top 5%.
- **Các khối có Sinh học:** Dù có điểm số thấp nhất trong tổ hợp 3 môn, Sinh học lại là môn có tính phân loại cao nhất để quyết định thứ hạng.

- **Ban KHXH:**

- **Quan sát & Ý nghĩa:** Các môn truyền thống (Văn, Sử, Địa) thiếu ổn định và liên tục đổi ngôi. Ngược lại, GD CD là một "biến số thiên lệch" (bias), luôn duy trì mức kích trần ở nhóm xuất sắc, trực tiếp đẩy tổng điểm lên mức tối đa.

4.4 Kết quả phân tích Trang 4: Không gian và địa lý giáo dục

Phân hệ này khai thác dữ liệu không gian dựa trên các chỉ số cốt lõi (điểm trung bình, tỷ lệ điểm xuất sắc) nhằm định vị các "điểm nóng" và làm rõ bức tranh phân hóa vùng miền trong giai đoạn 2020–2024.

4.4.1 Phân bố điểm xuất sắc (9–10 điểm)

- **Sự định hình của các "Siêu cực" và cụm vệ tinh:** Nhờ quy mô dân số và nguồn lực đầu tư, Hà Nội và TP. Hồ Chí Minh luôn đóng vai trò là hai "siêu cực" dẫn đầu tuyệt đối về số lượng điểm 9–10. Xoay quanh hai trung tâm này là các cụm vệ tinh thuộc Đồng bằng sông Hồng (Nam Định, Vĩnh Phúc) và dải Bắc Trung Bộ (Nghệ An, Thanh Hóa) luôn duy trì được mật độ điểm xuất sắc ở mức cao và ổn định.
- **Nhận diện "Vùng trắng" giáo dục:** Trái ngược với các điểm nóng, khu vực Tây Bắc Bộ, Tây Nguyên và phần lớn Đồng bằng sông Cửu Long duy trì trạng thái "vùng trắng" (cold spots) xuyên suốt 5 năm. Sự khan hiếm điểm 9–10 tại các khu vực này phơi bày thực trạng chênh lệch lớn trong khả năng tiếp cận giáo dục mũi nhọn.

4.4.2 Mặt bằng học lực chung thông qua Điểm trung bình

- **Tính ổn định tuyệt đối ở các môn công cụ:** Mặt bằng học lực Toán và Ngoại ngữ duy trì sự phân cấp rất vững chắc. Nam Định khẳng định vị thế thống trị môn Toán khi liên tiếp giữ Top 1 trong 4 năm (2021–2024, đỉnh điểm đạt 7.42 năm 2021). Trong khi đó, TP.HCM giữ vị thế độc tôn trọn vẹn 5 năm ở môn Ngoại ngữ (đạt 7.23 năm 2021).
- **Sự bứt phá tại khối Khoa học Tự nhiên:** Trái ngược với sự ổn định của Toán và Ngoại ngữ, mặt bằng các môn Lý, Hóa, Sinh chứng kiến sự cạnh tranh khốc liệt. Các tỉnh miền núi và vùng ven liên tục tạo bất ngờ, điển hình như Tuyên Quang (vươn lên Top 1 môn Hóa và Sinh các năm 2022, 2024) hay Vĩnh Phúc, Bắc Ninh (luân phiên dẫn đầu môn Vật lý).

4.4.3 Chiều sâu phân hóa mũi nhọn (Tỷ lệ học sinh ≥ 8 điểm)

- **Độ sâu chất lượng thực chất ở khối Tự nhiên và Ngoại ngữ:** Tỷ lệ mũi nhọn làm rõ nét sức mạnh đào tạo thực sự của các địa phương. Nam Định tạo ra khoảng cách áp đảo ở môn Toán (đạt 35.8% học sinh giỏi vào năm 2024, bỏ xa vị trí thứ hai). Tương tự, TP.HCM vượt trội về Ngoại ngữ khi duy trì tỷ lệ học sinh giỏi ở mức 32.4% (năm 2024), tạo ra một hố sâu ngăn cách so với nhóm xếp sau. Các môn Lý, Hóa cũng ghi nhận tính phân loại tốt với sự dẫn đầu của Vĩnh Phúc (48.0% môn Lý) và Tuyên Quang (44.2% môn Hóa).
- **Hiện tượng lạm phát điểm giỏi ở khối Khoa học Xã hội:** Dữ liệu bộc lộ sự thay đổi cấu trúc nghiêm trọng trong thang điểm môn Ngữ Văn và Địa Lý. Năm 2020, địa phương dẫn đầu môn Văn (Hà Nội) chỉ có 21.5% học sinh ≥ 8 điểm, nhưng đến năm 2024, con số này tại Ninh Bình vọt lên mức kỷ lục 70.9% (tăng gấp 3.3 lần). Sự bùng nổ tương tự xảy ra ở môn Địa Lý (Vĩnh Phúc đạt 60.6% năm 2024). Hiện tượng này cho thấy mốc điểm ≥ 8 ở các môn Xã hội đang dần mất đi sự khắt khe cần thiết để phân loại nhóm học sinh tinh hoa.

4.5 Kết quả phân tích Trang 5: Tương quan và phân hóa đề thi

4.5.1 Cấu trúc năng lực và tính độc lập của tổ hợp môn (Tương quan Pearson)

- **Quan sát trực quan:** Ma trận Heatmap (2020–2024) bị chia tách bởi hai vùng trắng (hệ số 0,00) do hệ quả từ quy chế thi (thí sinh không thi đồng thời khối KHTN và KHXH). Ở các khu vực có dữ liệu, cặp Lịch sử - Địa lý liên tục đậm màu dần (tăng từ 0,58 lên mức đỏ thẫm 0,66 vào năm 2024). Đồng thời, Toán học luôn duy trì tương quan cao với Vật lý ($\sim 0,56$ – $0,60$) và Ngoại ngữ ($\sim 0,57$ – $0,60$) qua tất cả các năm.
- **Nhận định và Ý nghĩa:** Dữ liệu khẳng định Toán học giữ vững vai trò là môn nền tảng kết nối mọi định hướng. Các khu vực tương quan cao (sắc đỏ đậm) làm nổi bật hai xu hướng học tập chủ đạo của thí sinh: tính gắn kết nội bộ ngày càng chặt chẽ của khối Xã hội (đặc biệt là Sử - Địa) và sự tồn tại vững chắc của nhóm tư duy logic kết hợp ngôn ngữ (Toán - Lý - Anh, tương ứng với tổ hợp A01 truyền thống).

4.5.2 Đặc thù giáo dục vùng miền (Đôi chuẩn Hà Nội và TP.HCM)

- **Quan sát:** Dữ liệu so sánh giai đoạn 2020–2024 bộc lộ sự khác biệt mang tính cấu trúc. TP. Hồ Chí Minh luôn giữ vị thế dẫn đầu ở môn Ngoại ngữ qua tất cả các năm. Ngược lại, Hà Nội liên tục chiếm ưu thế ở môn Ngữ văn với khoảng cách ngày càng mở rộng so với TP. Hồ Chí Minh. Riêng môn Toán, mức điểm trung bình của hai thành phố tương đương nhau và không có sự áp đảo rõ rệt.
- **Nhận định:** Sự phân hóa này phản ánh đặc thù định hướng giáo dục của mỗi vùng miền. TP. Hồ Chí Minh tập trung mạnh vào các công cụ hội nhập thực dụng, trong khi Hà Nội duy trì thế mạnh ở các môn khoa học cơ bản và tư duy ngôn ngữ học thuật.

4.5.3 Đánh giá năng lực phân hóa của cấu trúc đề thi (Phân tích Góc phân tư)

- **Quan sát và Phân nhóm:** Dựa trên độ khó (Điểm trung bình) và tính phân loại (Độ lệch chuẩn), các bài thi được phân thành 4 nhóm chính:
 - *Nhóm chuẩn mực (Phân hóa tốt):* Toán, Vật lý, Hóa học duy trì sự cân bằng giữa độ khó trung bình ($\sim 6,5$) và độ lệch chuẩn cao, là thước đo tin cậy nhất để tuyển sinh.
 - *Nhóm bộ lọc khắt khe:* Ngoại ngữ luôn có độ lệch chuẩn cao nhất ($\sim 2,0$), tạo ra độ giãn điểm cực lớn giữa các nhóm thí sinh dù mặt bằng chung là khó.
 - *Nhóm lạm phát điểm (Dễ và Kém phân hóa):* GD&ĐT luôn có điểm số cao nhất nhưng ít phân tán, cho thấy đề thi đang quá dễ và thiếu chức năng sàng lọc thí sinh xuất sắc.
 - *Nhóm chưa tối ưu:* Sinh học thường rơi vào vùng vừa khó vừa kém phân hóa, chưa đạt được mục tiêu đánh giá năng lực hiệu quả.
- **Ý nghĩa thực tiễn:** Phân tích này hỗ trợ các nhà quản lý giáo dục trong việc điều chỉnh cấu trúc đề thi, đặc biệt là cần chuẩn hóa lại độ khó của môn GD&ĐT và cải thiện tính phân loại của các môn Khoa học Xã hội để đảm bảo tính công bằng trong xét tuyển đại học.

5 Ứng dụng Trí tuệ Nhân tạo Trong Thiết Kế và Vận Hành Hệ Thống

5.1 Ứng dụng AI trong quá trình thiết kế

Để đảm bảo tính minh bạch, có thể kiểm chứng và tránh phụ thuộc vào đầu ra của AI, nhóm áp dụng nguyên tắc **“Human-first, AI-assisted”**: mọi phân tích và quyết định thiết kế đều được nhóm thảo luận độc lập trước, sau đó mới sử dụng AI để xác nhận, bổ sung hoặc phê bình. Toàn bộ vòng tương tác được ghi nhận bắt buộc theo chuỗi truy vết:

```
1 Prompt -> Script AI sinh ra -> Script sau khi nhóm chỉnh sửa -> Kết quả kiểm chứng
```

Chuỗi này được lưu trong file `ai-trace.md` và thư mục `logs/`, phục vụ báo cáo minh bạch về mức độ can thiệp của AI trong từng giai đoạn.

5.1.1 Hệ thống AI Prompt Helper chuẩn hóa

Nhóm thiết kế và lưu trữ một bộ **6 Prompt Helper chuyên biệt** trong thư mục `.github/prompts/`, mỗi helper phục vụ một giai đoạn cụ thể trong quy trình phát triển. Việc chuẩn hóa prompt giúp đảm bảo tính nhất quán trong các phiên làm việc khác nhau và giữa các thành viên trong nhóm.

gatekeeper — Kiểm định dataset đầu vào

Mục tiêu: Xác minh tập dữ liệu thô đáp ứng đầy đủ các tiêu chí bắt buộc của đề án trước khi tiến hành bất kỳ bước xử lý nào.

Nội dung kiểm định:

- Tổng số dòng dữ liệu ≥ 2.000 bản ghi
- Số biến độc lập ≥ 7 cột
- Tỷ lệ dữ liệu liên quan đến Việt Nam $> 50\%$ toàn tập
- Nguồn dữ liệu rõ ràng, có thể trích dẫn học thuật

Kết quả áp dụng: Nhóm xác nhận tập dữ liệu tổng hợp từ `thpt2020.csv` đến `thpt2024.csv` đạt hơn 4,6 triệu bản ghi, 11 biến chính, 100% dữ liệu Việt Nam — đáp ứng ngưỡng yêu cầu từ đề bài.

source-reliability — Đánh giá độ tin cậy nguồn dữ liệu

Mục tiêu: Kiểm tra và luận chứng tính đáng tin cậy, minh bạch của từng nguồn dữ liệu được sử dụng.

Các nguồn được đánh giá:

Nguồn	Nền tảng	Đánh giá
Điểm thi THPT 2020–2024	Kaggle	Dữ liệu gốc từ Bộ GD&ĐT, cộng đồng kiểm chứng
Tọa độ ranh giới hành chính	SimpleMaps	Nhà cung cấp bản đồ GIS uy tín quốc tế
Mã vùng tỉnh/thành	Tự tổng hợp	Đối chiếu với danh mục hành chính chính thức

Bảng 3: Đánh giá độ tin cậy các nguồn dữ liệu

Kết quả áp dụng: AI đề xuất bổ sung ghi chú nguồn trích dẫn trong báo cáo và khuyến nghị cố định phiên bản file `vn_geo.json` để tránh thay đổi ngoài ý muốn.

data-quality — Rà soát chất lượng dữ liệu

Mục tiêu: Phát hiện và định lượng các vấn đề chất lượng dữ liệu trước khi đưa vào phân tích.

Các hạng mục kiểm tra:

- **Giá trị khuyết thiếu (Missing values):** Xác định các dòng có toàn bộ cột điểm bằng NaN — tương ứng thí sinh đăng ký nhưng không dự thi.
- **Giá trị trùng lặp (Duplicates):** Kiểm tra số báo danh xuất hiện nhiều lần trong cùng năm.
- **Ngoại lệ (Outliers):** Rà soát điểm số nằm ngoài khoảng $[0, 10]$ do lỗi nhập liệu.

Kết quả áp dụng: AI sinh script phát hiện $\approx 3,2\%$ dòng rỗng trên tập 2020–2024. Nhóm quyết định loại bỏ các dòng này thay vì điền giá trị thay thế do tính chất dữ liệu thi cử.

cleaning-script — Sinh pipeline tiền xử lý tự động

Mục tiêu: Tự động hóa quy trình làm sạch và chuẩn hóa dữ liệu bằng Pandas, đảm bảo tính tái lập (reproducibility).

Các bước pipeline AI đề xuất:

1. Chuẩn hóa tên cột về định dạng thống nhất
2. Ghép nối 5 file CSV theo trục dọc (`pd.concat`)
3. Trích xuất mã vùng từ 2 ký tự đầu số báo danh
4. Merge với bảng `mavung.csv` để lấy tên tỉnh/thành
5. Loại bỏ dòng NaN toàn phần
6. Ép kiểu dữ liệu điểm về `float64`
7. Đồng bộ tên địa phương với `vn_geo.json`

Kết quả áp dụng: Nhóm chỉnh sửa thứ tự bước 3 và 4, bổ sung xử lý edge case cho mã vùng không khớp (ví dụ: “Hoàng Sa”, “Trường Sa”), sau đó kiểm chứng bằng cách so sánh tổng dòng trước và sau cleaning.

insight-hypothesis — Xây dựng giả thuyết phân tích

Mục tiêu: Với mỗi tab dashboard, AI được yêu cầu đề xuất 8 giả thuyết phân tích có tính phân hóa cao, kèm theo loại biểu đồ phù hợp và bằng chứng cần thu thập.

Ví dụ giả thuyết được AI đề xuất và nhóm kiểm chứng:

Tab	Giả thuyết	Kết quả
Tab 1	GDCD luôn là môn có điểm TB cao nhất	✓ Xác nhận, 5/5 năm
Tab 2	Ngoại ngữ có phân phối bimodal	✓ Rõ rệt năm 2021
Tab 3	GDCD là “bias variable” trong KHXH	✓ Top 5% KHXH cao hơn KHTN
Tab 4	Nam Định dẫn đầu Toán nhiều năm liên tiếp	✓ 4/5 năm (2021–2024)
Tab 5	Sử-Địa có tương quan Pearson tăng dần	✓ Tăng từ 0,58 lên 0,66

Bảng 4: Giả thuyết phân tích và kết quả kiểm chứng

Lưu ý: Nhóm bác bỏ 3/16 giả thuyết (H2, H7, H16) sau khi kiểm chứng thực tế với dữ liệu, thể hiện tính độc lập phân tích của nhóm so với đầu ra AI.

dashboard-critic — Phê bình thiết kế dashboard độc lập

Mục tiêu: Sau khi hoàn thiện mỗi tab, nhóm sử dụng helper này để AI đánh giá theo mỗi tab theo 6 tiêu chí: tính rõ ràng, phù hợp loại biểu đồ, liên kết logic giữa các visual, tương tác/điều hướng, sử dụng màu sắc, và chiều sâu phân tích.

Các cải tiến nhóm áp dụng từ phản hồi AI:

- Chuyển bản đồ từ dạng điểm sang Choropleth để thể hiện mật độ tốt hơn.
- Thêm tính năng hover tooltip chi tiết trên tất cả biểu đồ Plotly.
- Sắp xếp lại thứ tự Tab từ tổng quan → vi mô → không gian → thống kê.
- Thay Pie Chart ban đầu bằng Donut + 100% Stacked Bar (Dual-chart design) cho Tab 1 phần cơ cấu khối thi.

5.1.2 AI hỗ trợ lựa chọn loại biểu đồ phù hợp

Một trong những thách thức cốt lõi của trực quan hóa dữ liệu là lựa chọn đúng loại biểu đồ cho từng bài toán phân tích. Nhóm đã trình bày bài toán phân tích cụ thể và yêu cầu AI đề xuất các loại biểu đồ có thể sử dụng.

Bảng quyết định biểu đồ được AI tư vấn và nhóm phê duyệt:

Bài toán phân tích	Biểu đồ đề xuất	Lý do	Duyệt
Quy mô thí sinh theo thời gian	Area Chart	Nhấn mạnh tích lũy diện tích, rõ hơn Line Chart	✓
Phân phối điểm từng môn	Histogram	Thể hiện hình dáng phân phối tần suất	✓
Mức độ phân hóa đề thi	Boxplot	Bộc lộ median, IQR và outlier đồng thời	✓
Phổ điểm nhiều năm	Multi-year Line Chart	So sánh trực tiếp hình dáng đường cong	✓
Phân bố điểm theo tỉnh	Choropleth Map	Mã hóa không gian địa lý bằng màu sắc	✓
Đóng góp môn trong tổ hợp	Radar Chart	Biểu diễn đa trục trong cùng không gian	✓
Đối chuẩn HN vs. HCM	Dumbbell Chart	Tối ưu cho so sánh cặp giá trị	✓
Phân hóa & độ khó đề thi	Quadrant Bubble Chart	Phân vùng 4 góc chiến lược, bubble = quy mô	✓
Cơ cấu khối thi tỉnh	Donut Chart	Tỷ trọng phần trăm trong một thời điểm	✓
Xu hướng cơ cấu nhiều năm	100% Stacked Bar	Dàn trải tỷ trọng theo trục thời gian	✓

Bảng 5: Quyết định lựa chọn loại biểu đồ

Trong một số trường hợp, AI ban đầu đề xuất Scatter Plot cho bài toán tương quan nhưng nhóm đã quyết định ưu tiên Correlation Heatmap (dựa trên Pearson) để biểu diễn đồng thời toàn bộ 99 cặp môn học — quyết định này phản ánh sự phán xét độc lập của nhóm vượt ra ngoài gợi ý ban đầu của AI.

5.1.3 AI hỗ trợ thiết kế giao diện và hệ thống màu sắc

Nhóm sử dụng AI để xây dựng hệ thống visual nhất quán xuyên suốt 5 tab, đảm bảo người dùng có trải nghiệm liền mạch khi điều hướng giữa các phân hệ.

Các quyết định thiết kế được AI tư vấn:

- **Bảng màu chủ đạo:** AI đề xuất dải màu xanh đậm (navy blue) làm màu định danh thương hiệu cho toàn dashboard, kết hợp màu cam/vàng làm màu nhấn (accent) — tạo độ tương phản cao đảm bảo khả năng đọc cho người dùng khiếm thị màu sắc một phần.
- **Nguyên tắc màu có ý nghĩa (Semantic color encoding):**
 - Xanh đậm → nhóm KHTN
 - Cam/Vàng → nhóm KHXXH
 - Đỏ/Cam nóng → vùng điểm cao, mật độ cao trên Choropleth
 - Xanh nhạt → vùng điểm thấp, cold spots
- **Cấu trúc layout:** AI gợi ý sử dụng hệ thống 3 cột metric KPI ở hàng đầu mỗi tab (hiển thị tổng thí sinh, điểm trung bình, tỷ lệ key) trước khi dẫn vào các biểu đồ chi tiết bên dưới, theo mô hình “Overview → Detail”.
- **Typography và nhãn:** Đề xuất rút gọn nhãn dài (ví dụ: “Giáo dục công dân” → “GDCCD”) trên trục biểu đồ để tránh chồng chéo, đặc biệt trong Horizontal Bar Chart có nhiều danh mục.

5.1.4 AI hỗ trợ sinh mã nguồn Streamlit và Plotly

Quy trình sinh mã chuẩn của nhóm:

1. Nhóm tự viết pseudocode / logic thuật toán
2. Mô tả yêu cầu kỹ thuật cho AI (*input data format, output chart type, filter interaction*)
3. AI sinh mã Streamlit + Plotly hoàn chỉnh
4. Nhóm review, chỉnh sửa và kiểm thử thực tế với dữ liệu
5. Ghi nhận diff (trước/sau chỉnh sửa) vào `ai-trace.md`

Các module mã nguồn AI hỗ trợ sinh và nhóm hiệu chỉnh:

Module	Nội dung AI sinh	Chỉnh sửa của nhóm
Choropleth Map	Vẽ bản đồ <code>px.choropleth_mapbox</code> với GeoJSON	Đồng bộ key tên tỉnh, thêm hover template tùy chỉnh
Correlation Heatmap	Ma trận Pearson <code>go.Heatmap</code>	Ẩn tam giác trên, thêm annotation số liệu trong ô
Vision Chatbot	Luồng gửi ảnh base64 lên Gemini API	Thêm fallback khi API timeout, giới hạn context window
Boxplot đa năm	<code>go.Box</code> overlay nhiều năm	Thêm color map theo năm, toggle legend
Radar Chart	<code>go.Scatterpolar</code> cho Top 5% vs. Trung bình	Chuẩn hóa trục về cùng scale 0–10
100% Stacked Bar	<code>px.bar</code> với <code>barnorm="percent"</code>	Thêm data label phần trăm trong cột, format tooltip

Bảng 6: Các module mã nguồn: đầu ra AI và chỉnh sửa của nhóm

5.1.5 AI hỗ trợ phân tích và diễn giải dữ liệu

Quy trình phân tích có AI hỗ trợ:

1. Nhóm tự quan sát và ghi nhận nhận xét sơ bộ từ biểu đồ.
2. Mô tả hình dáng biểu đồ cho AI (dưới dạng văn bản hoặc hình ảnh) và yêu cầu diễn giải thống kê.
3. Đối chiếu diễn giải của AI với nhận xét của nhóm — ghi nhận điểm đồng thuận và bất đồng.
4. Nhóm đưa ra kết luận cuối cùng dựa trên cả hai nguồn.

Ví dụ minh họa — Phân tích phổ điểm Ngoại ngữ 2021:

Giai đoạn	Nội dung
Nhóm quan sát	Biểu đồ có hình dạng bất thường, không phải hình chuông.
AI diễn giải	Hiện tượng Bimodal distribution, phản ánh phân hóa năng lực giữa thí sinh thành thị và nông thôn.
Nhóm kiểm chứng	Tách dữ liệu theo địa phương, xác nhận đô thị lớn tạo đỉnh cao, tỉnh nhỏ tạo đỉnh thấp.
Kết luận cuối	Bổ sung phân tích chiều sâu về bất bình đẳng giáo dục ngoại ngữ.

Bảng 7: Quy trình phân tích có AI hỗ trợ: phổ điểm Ngoại ngữ 2021

5.1.6 AI hỗ trợ kiểm tra logic và debug

Các vấn đề logic được AI hỗ trợ giải quyết:

Lỗi	Nguyên nhân (AI chẩn đoán)	Cách khắc phục
Top 5% trả cùng giá trị mọi năm	Dùng <code>quantile(0.95)</code> trên toàn tập thay vì <code>groupby(năm)</code>	Thêm <code>groupby(['nam', 'khoi'])</code> trước khi gọi <code>quantile</code>
Correlation matrix trả về NaN	Thí sinh không thi đồng thời KHTN lẫn KHXH → cột toàn NaN	Bổ sung <code>min_periods=100</code> vào <code>df.corr()</code>
Choropleth thiếu 4 tỉnh	Tên tỉnh trong GeoJSON lệch ký tự so với DataFrame	Chuẩn hóa tên bằng <code>unidecode</code> + mapping thủ công
Chatbot lỗi encode ảnh	<code>st.pyplot</code> trả buffer không tương thích base64	Chuyển sang <code>format='png'</code> trong <code>plotly.io.to_image</code>

Bảng 8: Các lỗi logic, chẩn đoán và cách khắc phục

Mỗi lỗi được khắc phục đều đi qua quy trình: Nhóm tìm hiểu rõ nguyên nhân gốc → Chỉnh sửa code → Kiểm thử lại với dữ liệu thực

5.1.7 Quy trình lưu vết AI — file `ai-trace.md`

Theo yêu cầu của đề án, toàn bộ quá trình tương tác với AI được ghi nhận đầy đủ trong file `ai-trace.md` theo cấu trúc chuẩn hóa:

```

1 Session [N] - [dd/mm/yyyy]
2 +- Phân tích Human-first (bắt buộc, 2-5 dòng nhóm tự phân tích)
3 +- Task A
4 | +- Helper đã dùng
5 | +- Prompt gốc
6 | +- AI output (tóm tắt + file)
7 | +- Script AI sinh ra
8 | +- Script sau chỉnh sửa của nhóm
9 | +- Cách kiểm chứng
10 | +- Bảng chứng (ảnh/bảng/output)
11 | +- Rủi ro/giới hạn còn lại
12 +- Task B ...

```

5.2 Tích hợp Trợ lý ảo AI phân tích dữ liệu trực tiếp (Vision-based Chatbot)

Vượt ra khỏi mô hình Dashboard tĩnh truyền thống (nơi người dùng phải tự quan sát và rút ra kết luận), dự án đã hiện thực hóa khái niệm Phân tích dữ liệu hội thoại (Conversational BI) bằng việc tích hợp một Trợ lý ảo AI đa phương thức.

5.2.1 Ý tưởng thiết kế và Giá trị cốt lõi

- **Giải quyết rào cản phân tích:** Không phải người dùng cuối nào (học sinh, phụ huynh) cũng có khả năng đọc hiểu các biểu đồ phức tạp (như Boxplot, Scatter plot).

Trợ lý AI được sinh ra để đóng vai trò như một chuyên gia dữ liệu trung gian, giúp người dùng "hỏi đáp" trực tiếp với số liệu bằng ngôn ngữ tự nhiên.

- **Tận dụng trí tuệ đa phương thức (Multimodal LLM):** Thay vì chỉ truyền dữ liệu dưới dạng văn bản thô (text), hệ thống ứng dụng mô hình Gemini (phiên bản 2.5 Flash) có khả năng thị giác máy tính. AI sẽ trực tiếp "nhìn" vào biểu đồ giống như cách con người quan sát, từ đó đưa ra các nhận định trực quan và chính xác nhất.

5.2.2 Quy trình thu thập ngữ cảnh tự động

Để tối ưu hóa Trải nghiệm người dùng (UX), hệ thống được thiết kế để loại bỏ hoàn toàn các thao tác thủ công (như chụp màn hình, lưu file, tải ảnh lên). Quy trình diễn ra hoàn toàn tự động và liền mạch:

1. **Gắn kết thông minh:** Dưới mỗi biểu đồ trên Dashboard đều được hệ thống tự động đính kèm một nút chức năng "Phân tích với AI".
2. **Chụp ảnh và số hóa nội bộ:** Khi người dùng kích hoạt, hệ thống sẽ tự động chụp lại chính xác trạng thái biểu đồ hiện tại (đã bao gồm các bộ lọc năm, môn học, địa phương) thành một bức ảnh tĩnh sắc nét ở chế độ nền.
3. **Trích xuất siêu dữ liệu (Metadata):** Song song với hình ảnh, hệ thống ngầm bóc tách ý nghĩa của các trục tọa độ (Trục X đại diện cho yếu tố gì, Trục Y đo lường chỉ số nào) để chuẩn bị khung tham chiếu cho AI.

5.2.3 Luồng xử lý và trả lời truy vấn

Khi người dùng đặt câu hỏi (ví dụ: "Nhận xét giúp tôi xu hướng của phổ điểm này"), luồng thông tin sẽ được hệ thống đóng gói và xử lý qua các bước sau:

- **Thiết lập bối cảnh:** Hệ thống tổng hợp một gói dữ liệu bao gồm: Vai trò của AI (System Prompt), Hình ảnh biểu đồ vừa chụp, Ý nghĩa các trục đo lường, và Câu hỏi của người dùng.
- **Phân tích và Ràng buộc:** Việc cung cấp đồng thời hình ảnh thực tế và siêu dữ liệu ép buộc mô hình AI phải bám sát vào số liệu đang hiển thị trên màn hình. Điều này giúp ngăn chặn tối đa hiện tượng "ảo giác" (Hallucination) - tức là tình trạng AI tự bịa ra số liệu không có thật.
- **Phản hồi thời gian thực:** Kết quả phân tích được trả về ngay lập tức trên giao diện Chatbot dạng cửa sổ nổi (Popover). Đặc biệt, quá trình này hoạt động hoàn toàn độc lập, không làm tải lại trang hay làm mất đi các trạng thái bộ lọc mà người dùng đang thao tác trên Dashboard chính.



Hình 22: Ví dụ về sử dụng chatbot trong dashboard

6 Kết luận và hướng phát triển

6.1 Kết quả đạt được của đề tài

Sau quá trình nghiên cứu, thiết kế và phát triển, đề tài đã hoàn thành các mục tiêu ban đầu đặt ra và đạt được những kết quả cụ thể như sau:

- **Về mặt Khoa học Dữ liệu:** Đã xây dựng thành công một quy trình hoàn chỉnh (Data Pipeline) từ khâu thu thập, tiền xử lý, làm sạch đến phân tích một khối lượng lớn dữ liệu điểm thi THPT Quốc gia (giai đoạn 2020–2024).
- **Về mặt Xây dựng Hệ thống:** Thiết kế và triển khai thành công nền tảng Dashboard tương tác trực quan. Hệ thống cung cấp 5 phân hệ phân tích đa chiều (Tổng quan, Chi tiết môn học, Tổ hợp xét tuyển, Không gian địa lý, và Phân tích tương quan), đáp ứng tốt nhu cầu khai thác thông tin của nhiều nhóm người dùng.
- **Về mặt Tích hợp AI:** Ứng dụng Trí tuệ Nhân tạo vào hệ thống phân tích thông qua việc tích hợp Trợ lý ảo (Vision-based Chatbot). Tính năng này giúp phá bỏ rào cản kỹ thuật, cho phép người dùng truy vấn và tương tác với dữ liệu trực quan bằng ngôn ngữ tự nhiên.
- **Về mặt Thực tiễn:** Rút ra được những tri thức (Insights) có giá trị về mặt giáo dục, phản ánh bức tranh chênh lệch vùng miền, xu hướng chọn khối thi và năng lực phân hóa của đề thi, cung cấp cơ sở tham khảo cho học sinh, phụ huynh và các nhà quản lý giáo dục.

6.2 Hạn chế

Mặc dù đã đạt được những kết quả nhất định, hệ thống vẫn còn một số điểm giới hạn do rào cản về nguồn lực và thời gian nghiên cứu:

- **Giới hạn về tập dữ liệu:** Dữ liệu hiện tại chỉ tập trung vào điểm thi thuần túy. Hệ thống chưa được tích hợp các dữ liệu ngoại cảnh khác (như tỷ lệ trúng tuyển đại học, dữ liệu kinh tế - xã hội của các địa phương) để có thể tìm ra các mối tương quan nhân quả sâu sắc hơn.
- **Độ trễ của API Trợ lý ảo:** Việc gửi hình ảnh và trích xuất ngữ cảnh qua API của mô hình ngôn ngữ lớn đôi khi phụ thuộc vào băng thông mạng, dẫn đến độ trễ nhỏ trong quá trình phản hồi người dùng vào các khung giờ cao điểm.

6.3 Hướng phát triển tương lai

Để hoàn thiện và nâng cấp nền tảng, đề tài đề xuất các hướng phát triển tiếp theo trong tương lai:

- **Hệ thống Khuyến nghị (Recommendation System):** Xây dựng module tự động gợi ý tổ hợp môn học và ngành nghề phù hợp nhất dựa trên điểm số thi thử hoặc hồ sơ năng lực của từng cá nhân.
- **Mở rộng nguồn dữ liệu:** Tích hợp thêm các bộ dữ liệu về chỉ tiêu tuyển sinh của các trường Đại học, Cao đẳng, giúp hệ thống trở thành một cổng thông tin tuyển sinh toàn diện (All-in-one platform).

References

- [1] Streamlit Inc. Streamlit. <https://streamlit.io>, 2024.
- [2] Google. Google genai api documentation - gemini 2.5 flash. <https://ai.google.dev/docs>, 2024.
- [3] Plotly Technologies Inc. Plotly: Python open source graphing library. <https://plotly.com/python/>, 2024.